

基于大模型检索增强生成的地铁客服问答系统研究

刘恒宇¹, 蔺天震¹, 王 翠¹, 陈立乾²

(1. 青岛博宁福田智能交通科技发展有限公司研发中心, 山东 青岛 266111;

2. 青岛地铁运营有限公司线网管控中心, 山东 青岛 266101)

[摘 要] 针对基于知识图谱的地铁问答系统回答精准度较低以及大语言模型在客服问答中存在幻觉问题, 提出基于 Qwen2-7B 大语言模型, 并结合知识库构建、检索增强生成和提示词工程, 开发基于大模型检索增强生成的地铁客服问答系统。实验结果表明, 与基于知识图谱的系统 and 单独使用大语言模型相比, ROUGE-1 分别提升 32%、23%, ROUGE-L 分别提升 60%、51%, 回答准确率分别提升 65%、41%。此方案有效提升了回答的精准度, 减少了大模型生成的幻觉问题, 为地铁客服领域问答系统的设计提供参考。

[关键词] 大语言模型; 检索增强生成; 城市轨道交通; 智能交通; 智能客服

[中图分类号] TP182

[文献标识码] A

[文章编号] 1006-7523 (2025) 02-0055-07

DOI:10.16640/j.cnki.37-1222/t.2025.02.008

引 言

随着人工智能技术的迅猛发展, 大语言模型在自然语言处理领域的表现尤为引人注目。这些模型依托于深度学习算法和大规模数据集的训练, 展现出了在理解和生成自然语言方面特别是在语义理解与复杂推理任务中的强大能力。尽管如此, 在客服问答等实际应用场景中, 大语言模型仍需面对准确性与可靠性的挑战, 例如生成内容与用户输入任务及上下文语境的偏差。检索增强生成技术应运而生, 它通过融合检索与生成两大能力, 显著提高了大语言模型在问答系统中的

应用准确性和响应速度。

目前地铁车站管理趋于少人化、自助化和自动化, 各地地铁公司不断将智能化手段应用到车站和线路乘客服务领域。基于此背景蒲晓斌等提出由自助服务、远程客服和现场应援组成的三级智慧客服体系, 有效提升了服务水平、降低了运营成本^[1]。广州地铁上线智能客服终端设备, 可以实现对乘客语音自动应答功能, 有效减轻了工作人员压力^[2]。

城市轨道交通领域正经历着智能化的转型, 地铁客服问答系统的需求随之激增。该系统需提供准确的信息反馈, 并处理大量专业领域知识,

[收稿日期] 2024-12-07

[基金项目] 山东省交通运输厅科技计划项目 (2024B21)。

[作者简介] 刘恒宇 (1989—), 男, 青岛博宁福田智能交通科技发展有限公司研发中心, 工程师; 蔺天震 (1992—), 男, 硕士, 青岛博宁福田智能交通科技发展有限公司研发中心研发经理, 高级工程师; 王翠 (1987—), 女, 硕士, 青岛博宁福田智能交通科技发展有限公司研发中心, 高级工程师; 陈立乾 (1981—), 男, 硕士, 青岛地铁运营有限公司线网管控中心, 高级工程师。

以应对乘客多样化的问询需求。目前,将大语言模型与检索增强生成技术相结合,并利用外挂向量数据库进行专业领域知识的检索和召回,已成为业界的标准实践之一。本文设计并实现了一种基于大语言模型检索增强生成技术的地铁客服智能问答系统,旨在提升智能问答系统的准确率和效率。

一、相关工作

1. 大语言模型

大语言模型的主要技术包括Transformer架构、近端策略优化技术、人类反馈强化学习技术^[3]。Transformer架构自2017年由Google提出以来,已成为自然语言处理的核心技术,其通过自注意力机制替代了RNN(Recurrent Neural Network,循环神经网络)和CNN(Convolutional Neural Networks,卷积神经网络),并通过多头注意力增强模型表达能力。Transformer广泛应用于机器翻译、情感分析等多种自然语言处理任务,也被用于计算机视觉和音频处理。

近年来生成式大语言模型发展迅速,并不断在各行业应用落地。基于大语言模型的问答技术取得了显著进展,特别是在语义表示和复杂推理方面^[4]。Yuan^[5]设计了基于大模型的智能客服系统,通过大模型结合领域知识微调实现了特定领域的对话生成,并在真实场景数据集中全面评估了系统的有效性和实用性。Ma等^[6]设计了一种基于大语言模型结合LangChain技术框架的电信运营商客户服务体系,显著提高了电信行业知识推荐的接受率,提升了客户服务效率和体验。但是大语言模型也存在幻觉问题,模型生成的内容偏离了用户输入的任务和先前的上下文语境,看似合理但其实与事实相悖^[7]。

在轨道交通领域,大语言模型可以在线路规划和智能客服方面进行应用,前者通过多轮提示优化线路规划方案,后者通过多模态处理实现乘客服务的自动化和智能化^[8]。Jonnala,R.等^[9]研究了大语言模型在公共交通系统中的应用,特别是如何利用大语言模型优化线路规划、减少等待时间、提供个性化旅行协助。

2. 检索增强生成

检索增强生成是由Meta公司2020年提出的一种结合了预训练的参数化记忆和非参数化记忆的生成模型^[10]。参数化记忆是指模型内部的参数,这些参数在训练过程中被学习并存储在模型的权重中。非参数化记忆是指模型外部的知识库或信息源,这些信息源不依赖于模型的参数,可以在运行时动态更新。检索器是一个组件,负责根据输入查询从非参数化记忆中检索相关的文档。生成器是一个组件,负责根据输入和检索到的文档生成目标序列。检索增强生成模型通过端到端的方式联合训练检索器和生成器,不需要对检索到的文档进行直接监督。

文本嵌入技术可以作为检索增强生成系统的一部分,用于构建更准确的文档表示和查询理解。自然语言处理中的文本嵌入分为三类:基于频率的文本嵌入、基于神经网络的文本嵌入和基于主题建模的文本嵌入。包括Word2vec、GloVe、FastText、Doc2vec、ELMo和BERT等流行的嵌入模型^[11]。

检索增强生成技术能够通过结合检索和生成能力,有效提升大语言模型问答系统生成的准确性和时效性^[12]。洪亮等^[13]基于检索增强生成技术,构建了煤矿安全智能问答模型,实现了煤矿安全智能辅助预警决策。王祥昊等^[14]通过引入知识检索增强框架与大语言模型微调,提出了一种新型的铁路应急处置决策支持系统,实现了良好的应急处置策略的生成和处置任务分发。陶晓英^[15]综合运用检索增强生成、意图识别、大模型微调以及知识图谱构建等技术,构建了基于混合架构的大语言模型智能问答系统,实现了精准识别用户意图,降低大模型幻觉、有效解决了精准度低和偏见问题。

二、基于大模型检索增强生成的地铁客服问答系统设计

1. 总体架构

系统总体架构如图1所示,系统由知识数据模块、大语言模型模块以及问答模块三大核心模

块构成。知识数据模块包括文本嵌入模型、向量数据库、索引、文本分割器、文本加载器。大语言模型模块包含大语言模型、提示词工程。问答模块负责与用户的交互，集成了语音识别、文字转语音等功能。

从多个渠道收集地铁领域知识文档，并将音视频、图片文件转换为文本文档，进行数据预处理和清洗，然后利用嵌入模型将文本文档转换成

向量并存储在向量数据库中。

当有乘客进行语音问询时，系统识别乘客的语音输入并将其转换为查询文本，然后将乘客的查询文本转化为向量，并依据余弦相似度从向量数据库中检索出相关联的知识。然后，大语言模型依据预设的提示词模板生成准确的回答，并通过文字或语音的方式反馈给乘客。




图 1 大模型检索增强生成地铁客服问答系统总体架构图

2. 大模型选型

Qwen2 是由阿里云通义千问团队开发的一系列开源模型，涵盖了从 0.5 B 到 72 B 不同参数规模的预训练及指令微调模型，包括 Qwen2-0.5 B、Qwen2-1.5 B、Qwen2-7 B、Qwen2-57 B 和 Qwen2-72 B 五种尺寸。这些模型均采用了分组查询注意力机制，旨在加速推理过程并降低显存占用。在常识推理、代码生成、数学问题解决、翻译等多个下游任务中，Qwen2-72 B 展现出的性能不仅超越了美国顶尖的开源模型 Llama3-72 B，也优于众多闭源大模型。

在综合考量多个开源大模型的性能表现及实际场景需求，并特别关注模型参数规模与部署成本之间的平衡后，选择 Qwen2-7 B 作为本问答系统的基础大语言模型。

3. 向量数据库构建

通过青岛地铁公司的官方网站、微博官方账号、微信公众号、抖音账号等网络公开渠道抓取公开信息，并收集行业内标准规范、专业书籍以及青岛地铁公司内部文件等多源数据。

在数据预处理阶段，将音频、视频、图片等非文本数据转换为文本数据，以实现数据的统一

处理。随后对数据进行一系列精细化处理，包括敏感词过滤以保护隐私，相似度去重以提升数据质量，毒性消除以确保内容的安全性，以及格式规范检查以保证数据的一致性。处理后的数据被划分为乘客服务、线路运维、应急管理、安全运营四个类别，以满足不同场景下的查询需求。

将原始文档分块切分，每块大小设定为 256 个字符，并在块与块之间设置 64 个字符的重叠区域，以保证文本块之间的连续性。利用 text-embedding-v2 嵌入模型，为每个文本块生成了嵌入向量，并将其存储至 Milvus 向量数据库中。

4. 问题检索与答案生成

在构建向量数据库之后，将其配置为一个检索组件，该组件能够基于用户查询与已嵌入文本块之间的语义相似度，检索出额外的上下文信息，以增强问答系统的准确性。

当用户提出查询问题时，使用与之前相同的文本嵌入模型将问题转换成向量，以便与向量数据库中的向量进行比较。这一过程称为问题向量化。随后，通过计算向量之间的余弦相似度来检索与问题向量最相似的知识库片段。给定两个属性向量 A 和 B，其余弦相似度 $\cos(\theta)$ 由点积和向量长度给出，如公式 (1) 所示，其中 A_i 和 B_i

分别代表向量 A 和 B 的各分量。 $\cos(\theta)$ 值越接近 1，表示两个向量之间的相似度越高。

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}} \quad (1)$$

检索到的结果将根据相似度得分进行排序，选择最相关的片段作为后续生成的输入。这一步骤称为结果排序。最后，将检索到的相关片段与原始问题合并，形成更丰富的上下文信息以便更准确地生成回答，这一过程称为上下文融合。此外，提示词设计是与大规模语言模型进行交互时，用户输入的指令性或引导性文本，用于精准控制模型的输出。针对地铁客服问答系统所使用场景，本研究设计了特定的提示词，以优化问答系统的交互体验。提示词模板如下所示：

(1) 角色：

你是一个专业的地铁客服人员，能够在与用户的交互中，使用礼貌敬语，保持友好耐心的态度，为用户提供优质的服务体验。

(2) 技能：

技能 1: 知识库信息检索与应答

迅速从记忆中的知识库材料中检索相关信息。

精准匹配用户问题与知识库内容，并基于知识库信息向用户提供答复。

技能 2: 客服专业化应答

采用标准化客服语言，结合检索到的信息，以友好、耐心的语气构建回复。

在回复中加入敬语称呼，不限于“您好”，“尊敬的乘客”。

(3) 约束条件：

所有答案需基于知识库进行答复。对于不在知识库中的内容或者与青岛地铁服务无关的内容，请答复“我不知道这个问题，请换个问法试试”，并且不要加入其他任何信息。

你无需且严禁进行任何基于自身已了解知识的发散和响应。

回复中必须先使用敬语称呼，再回复具体问题。

回复尽量简短，减少不必要的冗余。

最后使用大语言模型基于上下文信息根据预设的提示词生成回答，当没有在知识库中检索到相关信息后，大模型直接输出“我不知道这个问题，请换个问法试试”的提示，避免大语言模型的生成幻觉的回答，影响乘客体验。

三、实验分析

1. 数据集

将收集到的原始数据经过包括文本标准化、敏感词过滤、相似度去重和毒性消除等一系列的数据预处理步骤，以及如文本抽取的数据增强处理后，从乘客服务、线路运维、应急管理、安全运营四类中分别抽取 10 条数据构建问题，形成一个包含 40 条测试问题的评测数据集，确保了数据集在不同类别中的均衡性和多样性。

评测数据集由两列构成：用户输入和模型期望输出。在模型评测过程中，基于评测集中的每一条用户输入进行推理，并利用自动化评分系统，将模型的推理结果与参考评测集中的模型期望输出进行对比评分。

评测数据集示例，如表 1 所示。

表 1 评测数据集示例表

分类	用户输入	期望输出
乘客服务	青岛地铁是如何确定票价的？	起步价 2 元，起步里程 5 公里。5 ~ 10 公里（含），票价为 3 元。10 ~ 17 公里（含），票价为 4 元。17 ~ 27 公里（含），票价为 5 元。27 ~ 38 公里（含），票价为 6 元。38 公里以上部分，票价每增加 1 元，可多乘坐 20 公里。
线路运维	运营单位可以采取哪些措施加强服务质量监督？	运营单位宜邀请乘客代表或常乘客参与服务质量监督工作，同时根据服务质量准则进行评价和改进，并建立投诉受理、建议收集机制，明确投诉处理流程并在规定时间内反馈结果。另外，还需要在车站及列车上公布监督投诉电话，并通过各种渠道收集公众的意见和建议。
应急管理	为什么要客流控制？	为了保障乘客乘车安全，如遇客流较大情况，会进行客流控制，避免因密闭空间过度拥挤造成的意外事件，感谢您的理解。
运营安全	地铁通道过街需要安检吗？	经由地铁通道过街的市民，如不经安检口进入付费区域，可以不用进行安全检查。另外如遇重大活动时期青岛地铁根据上级要求落实反恐防范措施时，则不能通过地铁通道过街。

2. 评价指标

在问答系统生成任务中，ROUGE（Recall-Oriented Understudy for Gisting Evaluation）常被用作评价指标。其中 ROUGE-1 是模型输出与参考摘要在 1 元词层面的召回率，其值越接近 1，表明模型输出与参考答案的一致性越高。ROUGE-L 指标则基于模型输出与参考摘要之间的最长公共子序列来计算召回率。该指标的取值范围为 0 至 1，其中 1 代表完全一致，0 则表示完全不匹配，适用于评估文本的流畅性和连贯性。

ROUGE-1 表达式如公式（2）所示：

$$ROUGE-1 = \frac{\sum_{S \in ReferenceSummaries} \sum_{gram_1 \in S} Count_{match}(gram_1)}{\sum_{S \in ReferenceSummaries} \sum_{gram_1 \in S} Count(gram_1)} \quad (2)$$

ROUGE-L 指标基于两个文本单元的最长公共序列，计算 F-measure，具体如公式（3）（4）（5）所示：

$$R_{LCS} = \frac{LCS(C, S)}{len(S)} \quad (3)$$

$$P_{LCS} = \frac{LCS(C, S)}{len(C)} \quad (4)$$

$$F_{LCS} = \frac{(1 + \beta^2)R_{LCS}P_{LCS}}{R_{LCS} + \beta^2P_{LCS}} \quad (5)$$

本文采用 ROUGE-1、ROUGE-L 和准确率这三个指标，对基于知识图谱的问答系统、基于大语言模型的问答系统以及基于大模型检索增强生成的问答系统进行对比测试。ROUGE-1 关注词汇覆盖，确保模型生成的文本包含关键信息；ROUGE-L 关注全局匹配，评估文本的整体连贯性和逻辑顺序，设定 ROUGE-L 分值阈值为 0.4，超出阈值时认为生成结果是准确的；准确率评估

系统回答的准确性。

3. 实验环境

在本研究中，构建了两种类型的应用系统。第一种是针对问答系统定制的智能体应用，整合了大模型、提示词、知识库等关键组件，创建基于大语言模型的问答系统以及基于大模型检索增强生成的问答系统。第二种是 workflow 应用，通过 API 节点引入已有的基于知识图谱的问答系统，用于对现有的知识图谱的问答系统进行评测。

4. 实验结果

为了确保测试结果的可靠性和统计显著性，本研究对三个系统进行了三次独立的实验测试，并取其均值进行比较。为方便描述，本节中用知识图谱系统代指基于知识图谱的问答系统，用大模型系统代指基于大语言模型的问答系统。

三个系统的评测分数结果，如表 2 和图 2 所示。

具体分析可得：

（1）ROUGE-1 平均值比较：知识图谱系统为 0.66，大模型系统为 0.71，大模型检索增强生成系统为 0.85。大模型检索增强生成系统的平均 ROUGE-1 得分最高，大模型系统次之，知识图谱系统最低。

（2）ROUGE-L 平均值比较：知识图谱系统为 0.46，大模型系统为 0.49，大模型检索增强生成系统为 0.74。大模型检索增强生成系统的平均 ROUGE-L 得分最高，大模型系统次之，知识图谱系统最低。

（3）准确率（Acc）平均值比较：知识图谱系统为 0.46，大模型系统为 0.54，大模型检索增

表 2 系统评测分数表

系统	ROUGE-1				ROUGE-L				Acc			
	1 轮	2 轮	3 轮	平均	1 轮	2 轮	3 轮	平均	1 轮	2 轮	3 轮	平均
知识图谱系统	0.68	0.66	0.65	0.66	0.44	0.48	0.46	0.46	0.48	0.46	0.45	0.46
大模型系统	0.71	0.7	0.73	0.71	0.48	0.49	0.51	0.49	0.53	0.54	0.55	0.54
大模型检索增强生成系统	0.85	0.89	0.87	0.87	0.72	0.76	0.74	0.74	0.76	0.78	0.73	0.76




图 2 系统评测结果图

强生成系统为 0.76，可以看出，大模型检索增强生成系统的平均准确率最高，显著高于其他两个系统；大模型系统次之；知识图谱系统的平均准确率最低。

（4）数据波动性和稳定性分析：知识图谱系统在各指标的波动范围均较小，特别是 ROUGE-1 和准确率，波动仅为 0.03，虽然性能评分较低，但稳定性较好。大模型系统在准确率指标上波动最小，仅为 0.02，表现出最高的稳定性。在 ROUGE-1 和 ROUGE-L 指标上的波动也较小，说明该系统性能稳定，受外部因素影响较小。大模型检索增强生成系统在各指标上的波动略大，准确率波动为 0.05，但仍在可接受范围内，总体得分高，性能优秀。

经过三轮评测，发现基于大模型检索增强生成的问答系统在 ROUGE-1、ROUGE-L、准确率这三个关键性能指标上均展现出显著的领先优势。其在两个 ROUGE 指标上均有较高得分，说明其生成内容在词汇匹配和长序列匹配上都有优势，并且在 ROUGE 和 Acc 指标上都表现优秀，

表明其生成的内容不仅形式上与参考答案接近，实质上也具有高准确性。

四、总结与展望

文中采用 Qwen2-7B 大语言模型和检索增强生成技术，构建了地铁客服问答系统，通过将地铁领域专业知识构建向量知识库，乘客问询时系统通过检索知识库内已存在知识根据提示词模板进行结果输出返回给乘客。通过对比实验表明，该系统对比传统的知识图谱问答系统和单纯大语言模型 ROUGE-1 分别提升了 32%、23%，ROUGE-L 分别提升了 60%、51%，准确性分别提升了 65%、41%。基于大模型检索增强生成的地铁客服问答系统能够有效解决回答精准度低和大模型生成幻觉问题。

未来将聚焦于进一步提升模型性能和扩充知识库的数据量，二次预训练和指令微调，同时结合实际场景运行效果反馈，对系统进行持续优化，以提高其准确性和适用性。

〔参考文献〕

[1] 蒲晓斌, 张炳森, 李世君, 等. 运营新模式下城市轨道交通智慧客服体系的建设 [J]. 现代城市轨道交通, 2024(5):27-32.

[2] 曾文键. 城市轨道交通智能客服终端的应用研究 [J]. 自动化应用, 2023,64(02):25-28.

[3] 蔡睿, 葛军, 孙哲, 等. AI 预训练大模型发展综述 [J]. 小型微型计算机系统, 2024,45(10):2327-2337.DOI:10.20009/j.cnki.21-1106/TP.2023-0571.

[4] 文森, 钱力, 胡懋地, 等. 基于大语言模型的问答技术研究进展综述 [J]. 数据分析与知识发现, 2024,8(06):16-29.

[5] Xi Y. Research and Application of Large Model-Based Intelligent Customer Service System[J]. International Journal of Emerging Technologies

- and Advanced Applications, 2024, 1(3): 12–16.
- [6] Xiaoliang M, RuQiang Z, Ying L, et al. Design of a large language model for improving customer service in telecom operators[J]. Electronics Letters, 2024, 60(10): e13218.
- [7] 张铮, 刘晨旭. 大模型幻觉: 人机传播中的认知风险与共治可能 [J]. 苏州大学学报 (哲学社会科学版), 2024, 45(05): 171–180.
- [8] 黄霁. 大模型 AI 在轨道交通中的应用探讨 [J]. 智能建筑电气技术, 2024, 18(2): 25–31.
- [9] Jonnala R, Liang G, Yang J, et al. Using Large Language Models in Public Transit Systems, San Antonio as a case study[J]. arXiv preprint arXiv:2407.11003, 2024.
- [10] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459–9474.
- [11] 赵悦阳, 崔雷. 文本嵌入技术的研究与应用进展 [J]. 数据与计算发展前沿, 2023, 5(3): 92–110.
- [12] 陈冬雷, 秦薇. 基于检索增强生成的智能问答系统关键技术研究 [J]. 办公自动化, 2024, 29(19): 82–86.
- [13] 洪亮, 郭瑶, 刘兴丽, 等. 基于 RAG 的煤矿安全智能问答模型 [J]. 黑龙江科技大学学报, 2024, 34(03): 487–492.
- [14] 王祥昊, 杨怀志, 王莉, 等. 基于语义理解与生成模型的铁路应急处置决策支持系统 [J]. 铁道技术标准 (中英文), 2024, 6(06): 44–51.
- [15] 陶晓英. 基于混合架构的大语言模型智能问答系统研究 [J]. 邮电设计技术, 2024(05): 48–55.

Research on Metro Customer Service Question-Answering System Based on Large Language Model Retrieval Augmented Generation

LIU Heng-yu¹, LIN Tian-zhen¹, WANG Cui¹, CHEN Li-qian²

(1. R&D Center, Qingdao Bonin Fortune Intelligent Transportation Technology Development Co., Ltd., Qingdao 266111, China;

2. Line Network Control Center, Qingdao Metro Operation Co., Ltd., Qingdao 266101, China)

Abstract: Aiming at the low answer accuracy of metro Q&A system based on knowledge graph and the illusion of large language model in customer service Q&A system, a metro customer service Q&A system based on large language model Qwen2-7B was proposed, and combined with knowledge base construction, retrieval-augmented generation and prompt engineering, a metro customer service Q&A system based on large language model retrieval-augmented generation was developed. The experimental results show that compared with the knowledge graph-based system and the large language model alone, ROUGE-1 improves 32%, 23%, ROUGE-L improves 60%, 51%, and the answer accuracy improves 65% and 41%, respectively. This solution effectively improves the accuracy of the answer, reduces the illusion problem generated by the large model, and provides a reference for the design of the question and answer system in the field of metro customer service.

Key Words: large language model, retrieval augmented generation, urban rail transit, intelligent transportation, intelligent customer service